

## Етап підготовки та аналізу даних

### Лабораторна робота №1: Комплексний дослідницький аналіз даних, просунута попередня обробка та аугментація даних для моделей машинного навчання

**Мета:** Навчитися проводити глибокий дослідницький аналіз даних (EDA), виявляти складноструктуровані аномалії, застосовувати методи аугментації / синтезу даних для вирішення проблеми дисбалансу чи обмеженого обсягу вибірки.

#### Завдання:

##### 1. Вибір та обґрунтування датасету

- Обрати складний публічний датасет із табличними даними з Kaggle або UCI Machine Learning Repository.
- **Вимоги до датасету:**
  - Не менше 10 ознак (числові + категоріальні).
  - Наявність дисбалансу класів (для задачі класифікації) або вираженої асиметрії/мультиколінеарності (для задачі регресії).

##### 2. Глибокий дослідницький аналіз (Advanced EDA)

###### Аналіз розподілів та кореляцій:

Побудувати матриці кореляцій (Пірсона та Спірмена), виявити мультиколінеарність. Перевірити числові ознаки на нормальність розподілу (візуально та за допомогою статистичних тестів, наприклад, Шапіро-Уїлка або Д'Агостіно).

###### Аналіз аномалій та викидів (Outlier Detection):

Порівняти декілька підходів до виявлення викидів: класичний межквартильний інтервал (IQR), Z-score та ансамблевий метод (наприклад, Isolation Forest або Local Outlier Factor).

##### 3. Комплексна обробка та трансформація даних

###### Заповнення пропусків (Imputation):

Порівняти базову імпутацію (медіана/мода) із просунутою (наприклад, KNNImputer або IterativeImputer / MICE).

###### Кодування категоріальних ознак:

Застосувати кодування залежно від типу ознак: Target Encoding або Frequency Encoding для високопотужних категоріальних змінних, та One-Hot Encoding / Ordinal Encoding для інших.

###### Нормалізація та геометричні перетворення:

Застосувати масштабування (RobustScaler або PowerTransformer / Box-Cox для усунення скошеності розподілу).

##### 4. Аугментація та генерування даних (Data Augmentation & Generation)

###### Синтез нових спостережень (для табличних даних):

Застосувати алгоритми передискретизації та аугментації для подолання дисбалансу класів або розширення вибірки: **SMOTE**, **ADASYN**, або додавання керованого гаусового шуму крізь розбивку даних.

**Інженерія ознак (Feature Engineering):**

Згенерувати нові синтетичні ознаки на основі взаємодії існуючих (нелінійні комбінації, поліноміальні ознаки, агрегації за категоріями).

## **5. Оформлення підсумкового звіту**

Звіт повинен містити:

- Опис датасету та результати EDA (з графіками та висновками).
- Обґрунтування вибору методів імплементації, кодування та аугментації.

Кожне завдання можна реалізувати з використанням популярних бібліотек (наприклад, Scikit-learn, TensorFlow, PyTorch) та мови програмування Python.