Етап розробки та навчання моделі

Лабораторна робота №3: Оптимізація гіперпараметрів, вкладена крос-валідація та дослідження витоку даних (Data Leakage)

Мета роботи: Навчитися застосовувати методи оптимізації гіперпараметрів та крос-валідації; дослідити вплив вибору алгоритму пошуку на обчислювальну складність і якість моделей; опанувати методологію запобігання витоку даних та застосування вкладеної крос-валідації (Nested Cross-Validation).

Завдання для виконання

Етап 1. Підготовка даних та створення baseline-моделі

Обрати модель з Лабораторної роботи №2 (з високою кількістю гіперпараметрів або схильну до перенавчання, наприклад: Random Forest, XGBoost, Support Vector Machine, Gradient Boosting).

Зафіксувати метрику якості відповідно до типу задачі (наприклад, F_1-score, ROC-AUC для класифікації або RMSE/MAE для регресії).

Етап 2. Дослідження 1: Порівняння методів оптимізації (Grid vs. Random vs. Bayesian)

Визначити простір гіперпараметрів для обраної моделі (не менше 3–4 параметрів).

Провести оптимізацію трьома методами:

Full Grid Search (GridSearchCV)

Random Search (RandomizedSearchCV) з N={20,50} ітераціями

Bayesian Optimization (використовуючи Optuna або BayesSearchCV) з N = 20 ітераціями

Зафіксувати час виконання кожної стратегії та найкраще значення валідаційної метрики.

Етап 3. Дослідження 2: Оцінка впливу Data Leakage

Побудувати два експериментальних пайплайни:

Некоректний пайплайн (з витоком)

Коректний пайплайн (без витоку)

Порівняти отримані валідаційні метрики та оцінити величину штучного завищення якості.

Етап 4. Дослідження 3: Оцінка незміщеної якості (Nested Cross-Validation)

Реалізувати схему Вкладеної крос-валідації:

Зовнішня петля: K=5 фолдів для оцінки узагальнювальної здатності.

Внутрішня петля: K=3 фолди для підбору гіперпараметрів .

Порівняти тестову оцінку з внутрішньої CV та незміщену оцінку із зовнішньої CV у Nested CV.

Вимоги до звіту та підсумкового аналізу

У звіті обов'язково мають бути присутні:

Порівняльна таблиця методів оптимізації:

Метод оптимізації	**Кількість ітерацій / оцінок**	**Час виконання (сек)**	**Best Score (Inner CV)**	**Unbiased Score (Nested CV)**

Порівняння витоку даних: Таблиця/графік різниці метрик для коректного та некоректного препроцесингу.

Графік залежності "Якість моделі / Час обчислень".

Висновки: Обґрунтування доцільності вибору того чи іншого методу оптимізації для реальних задач із врахуванням обмежених обчислювальних ресурсів.