МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
Національний університет «Львівська політехніка»
Інститут комп’ютерних наук та інформаційних технологій
Кафедра «Системи штучного інтелекту»



ЛАБОРАТОРНА РОБОТА №2

з дисципліни
«Методологія та процеси моделювання у штучному інтелекті»

на тему
Порівняння традиційних ML-алгоритмів для задачі класифікації

Виконав:
студент групи КНСШ-13
Галич Максим

Викладач:
Косаревич Р.Я.

Львів — 2026

Мета роботи. Ознайомитися з основними алгоритмами машинного навчання та навчитися обирати й порівнювати їхню ефективність для конкретної задачі.

Усі обчислення виконано мовою Python із бібліотеками scikit-learn та imbalanced-learn. Код продовжує пакет `mk1` з лабораторної роботи №1: сценарії підготовки даних і моделі описано в модулі `scenarios.py`, порівняння — у `comparison.py`, дослідження перенавчання — в `overfitting.py`. Сценарій `lab2/run.py` лише запускає етапи по черзі й перевіряє, що кожен записав свої рисунки та метрики. Увесь експеримент відтворюється однією командою з фіксованим зерном генератора випадкових чисел.

1. ПОСТАНОВКА ЗАДАЧІ ТА ВИХІДНІ ДАНІ

Використано набір даних, підготовлений у лабораторній роботі №1: **Diabetes 130-US Hospitals for Years 1999–2008** [1]. Після очищення він містить **69 987** незалежних пацієнтів (для кожного залишено першу госпіталізацію) і 46 числових та категоріальних ознак. Цільова змінна — повторна госпіталізація протягом 30 днів після виписки, тож задача є **бінарною класифікацією**. Клас 1 становить 8,98 % спостережень, співвідношення класів 1 : 10,1.

Розбиття на навчальну та тестову вибірки взято без змін з лабораторної роботи №1: стратифіковане, 80 % на 20 %, з тим самим зерном. Навчальна вибірка містить 55 989 пацієнтів, тестова — 13 998, з яких 1 257 були повторно госпіталізовані. Усі порівняння в розділах 5–6 виконано крос-валідацією на навчальній вибірці. Тестову вибірку використано один раз, у розділі 8, для перевірки висновків.

2. СЦЕНАРІЇ ПІДГОТОВКИ ДАНИХ

2.1. Опис сценаріїв

Порівняння виконано на трьох сценаріях підготовки даних, які вимагає завдання (табл. 2.1). Сценарій В виконано у двох варіантах: з методом SMOTE [2] і з методом ADASYN [3].

Таблиця 2.1. Перетворення даних у сценаріях порівняння

Етап	**А: мінімальне очищення**	**Б: повне очищення**	**В: очищення + аугментація**
Записи	однакові в усіх сценаріях: перша госпіталізація кожного пацієнта, без випадків смерті та переведення до хоспісу; службові коди «NULL» і «Not Mapped» замінено на пропуски		
Пропуски категоріальних ознак	найчастіше значення (мода)	окрема категорія «Missing»	як у Б
Високопотужні категоріальні ознаки	One-Hot з об’єднанням категорій, рідших за 50 записів	Target Encoding з перехресним навчанням [4]	як у Б
Інші категоріальні ознаки	One-Hot	One-Hot	як у Б
Вік	порядкове кодування	порядкове кодування, стандартизація	як у Б
Числові ознаки	без перетворень	`RobustScaler`	як у Б
Інженерія ознак	немає	доменні ознаки, групи діагнозів МКХ-9, відхилення від середнього за категорією	як у Б

Етап	А: мінімальне очищення	Б: повне очищення	В: очищення + аугментація
Балансування класів	немає	немає	SMOTE або ADASYN до співвідношення 1 : 1, лише на навчальних блоках

Записи в усіх сценаріях однакові. Очищення на рівні записів не є вибором методу обробки, а умовою коректного оцінювання. Без нього госпіталізації одного пацієнта потрапили б і до навчальної, і до валідаційної частини, і метрики сценарію А були б завищені витоком даних, а не відображали б якість обробки. Отже, сценарії відрізняються лише тим, що зроблено з ознаками, і різниця в метриках є наслідком саме цього.

Сценарій А — це мінімум обробки, без якого бібліотека scikit-learn не прийме дані: пропуски заповнено модою, категорії закодовано One-Hot, числові ознаки подано як є (лістинг 1). Рідкісні категорії все ж об’єднано: без цього лише коди діагнозів дали б близько 2000 стовпців, переважно порожніх.

```
    onehot = OneHotEncoder(
        handle_unknown="infrequent_if_exist",
        min_frequency=ONEHOT_MIN_FREQUENCY,
        sparse_output=False,
        dtype=np.float32,
    )
    encode = ColumnTransformer(
        [
            ("num", "passthrough", NUMERIC),
            ("age", OrdinalEncoder(categories=[AGE_ORDER]), ["age"]),
            ("cat", onehot, CATEGORICAL),
        ],
        remainder="drop",
        sparse_threshold=0.0,
    )
    return [
        ("select", ColumnSelector((*CATEGORICAL, "age", *NUMERIC))),
        ("impute", CategoricalImputer(strategy="mode")),
        ("encode", encode),
    ]
```

Лістинг 1. Мінімальна обробка сценарію А (`src/mk1/scenarios.py`)

Сценарій Б — підсумковий конвеєр лабораторної роботи №1, кожен крок якого обрано за результатами крос-валідації. Пропуски категоріальних ознак заповнено окремою категорією «Missing», а не імп'ютацією: у лабораторній роботі №1 цей спосіб переміг моду та імп'ютацію методом k найближчих сусідів, бо сам факт пропуску пов'язаний із ціллю (пропуск коду платника чи спеціальності лікаря — ознака певного типу госпіталізації). Числові ознаки цього набору даних пропусків не мають. Для всіх трьох моделей використано одну конфігурацію, щоб сценарій був властивістю даних, а не моделі. У лабораторній роботі №1 деревоподібні моделі були байдужі до вибору кодування та масштабування в межах розкиду між блоками.

Сценарій В додає до сценарію Б передискретизацію класу 1. SMOTE створює нову точку на відрізку між записом класу 1 та одним із його п'яти найближчих сусідів того ж класу. ADASYN генерує більше точок біля записів, серед сусідів яких більше записів класу 0, тобто біля межі класів. Обидва методи працюють у закодованому числовому просторі, після кроку попередньої обробки.

Кожен сценарій зібрано в один конвеєр бібліотеки imbalanced-learn (лістинг 2). Усі кроки, що навчаються на даних (групові середні, кодувальники, масштабування, передискретизація), стоять усередині конвеєра. Під час крос-валідації їх заново навчають на навчальних блоках, а до валідаційного блоку лише застосовують. Передискретизація виконується тільки під час навчання, тож оцінювання завжди відбувається на реальних пацієнтах.

```
    match name:
        case "logreg" | "hgb":
            return make_model(name, balanced=False)
        case "rf":
            return RandomForestClassifier(
                n_estimators=300,
                max_features="sqrt",
                min_samples_leaf=RF_MIN_LEAF,
                n_jobs=-1,
                random_state=SEED,
            )
    raise ValueError(f"Unknown model: {name}")


def build_scenario(scenario: Scenario, model: str) -> Pipeline:
    """
```

```
    Assemble the pipeline of one scenario ending in one classifier.

    Args:
        scenario: The data preparation to apply.
        model: One of MODELS.

    Returns:
        An unfitted imbalanced-learn Pipeline; its sampler, if any, acts
        during fit only, so validation and test rows are never resampled.
    """
    if scenario.variant is None:
        steps = minimal_steps()
    else:
        # Lab 1's preprocessing and sampling steps, unchanged. build_pipeline
        # needs a model name to be complete; its classifier is dropped here.
        steps = build_pipeline(scenario.variant, "logreg").steps[:-1]
    return Pipeline([*steps, ("model", make_classifier(model))])
```

Лістинг 2. Класифікатори та збирання конвеєра сценарію (`src/mk1/scenarios.py`)

2.2. Стан даних після перетворень

Стан навчальної матриці, яку отримує класифікатор у кожному сценарії, наведено в табл. 2.2 (для всієї навчальної вибірки).

Таблиця 2.2. Навчальна матриця після перетворень кожного сценарію

Сценарій	Записів	З них синтетичних	Частка класу 1	Ознак
A: мінімальне очищення	55 989	0	8,98 %	563
Б: повне очищення	55 989	0	8,98 %	113
В: очищення + SMOTE	101 922	45 933	50,00 %	113
В: очищення + ADASYN	100 307	44 318	49,19 %	113

Сценарій А дає найширшу матрицю: One-Hot кодування високопотужних ознак перетворює сім стовпців на сотні бінарних. Target Encoding у сценарії Б замінює

кожну з цих ознак одним числом, тож матриця вужча в п’ять разів, попри додані доменні ознаки. Аугментація в сценарії B майже подвоює кількість записів: на кожного реального пацієнта класу 1 припадає близько дев’яти синтетичних.

3. АЛГОРИТМИ КЛАСИФІКАЦІЇ

Для порівняння обрано три алгоритми з різними принципами роботи (лістинг 2, функція `make_classifier`):

- **логістична регресія** (L2-регуляризація, $C = 1$, розв’язувач L-BFGS, до 3000 ітерацій): лінійна модель, що оцінює ймовірність класу 1 логістичною функцією від зваженої суми ознак;
- **випадковий ліс** [5] (300 дерев, $\sqrt{p}$ випадкових ознак у кожному вузлі, щонайменше 10 записів у листку): ансамбль дерев рішень, навчених на бутстреп-вибірках; прогноз — середнє прогнозів дерев;
- **гістограмний градієнтний бустинг** [6, 7] (250 дерев, крок навчання 0,05, до 31 листка в дереві, L2-регуляризація 1): дерева будуються послідовно, кожне виправляє похибки попередніх; значення ознак попередньо групуються в 255 інтервалів, що прискорює пошук розбиттів.

Гіперпараметри логістичної регресії та бустингу взято з лабораторної роботи №1. Мінімальний розмір листка випадкового лісу обрано за найвищою PR-AUC на крос-валідації серед значень 1, 3, 10, 30 і 100 (розділ 6.3).

Метод опорних векторів (SVM) до порівняння не включено. Час навчання SVM з ядром зростає приблизно пропорційно квадрату кількості записів або швидше [8], а в цьому експерименті модель довелося б навчити понад сто разів на 45–100 тисячах записів. Крім того, SVM не дає ймовірностей без додаткової калібровки на окремій крос-валідації, а саме ймовірності потрібні для ROC-AUC, PR-AUC та вибору порога.

4. МЕТОДИКА ОЦІНЮВАННЯ

Кожну пару «сценарій — модель» оцінено стратифікованою 5-блоковою крос-валідацією на навчальній вибірці (лістинг 3) і подано як середнє ± стандартне відхилення між блоками.

```
    folds = StratifiedKFold(n_splits=CV_FOLDS, shuffle=True, random_state=SEED)
    y_all = y.to_numpy()
    oof = np.zeros(len(y), dtype=float)
    valid_parts, train_rows, as_new, synthetic_recall, seconds = [], [], [], [], []
    converged = True
    for train_idx, valid_idx in folds.split(X, y):
        pipe = build()
        started = time.perf_counter()
        Xt, yt = fit_on_matrix(pipe, X.iloc[train_idx], y.iloc[train_idx])
        seconds.append(time.perf_counter() - started)
        model = pipe.named_steps["model"]
        if (
            isinstance(model, LogisticRegression)
            and model.n_iter_.max() >= model.max_iter
        ):
            converged = False

        oof[valid_idx] = pipe.predict_proba(X.iloc[valid_idx])[:, 1]
        n_real = len(train_idx)
        train_proba = model.predict_proba(Xt[:n_real])[:, 1]
        train_rows.append(classification_scores(yt[:n_real], train_proba, 0.5))
        new_proba = pipe.predict_proba(X.iloc[train_idx])[:, 1]
        as_new.append(classification_scores(yt[:n_real], new_proba, 0.5))
        if len(Xt) > n_real:
            synthetic = model.predict_proba(Xt[n_real:])[:, 1]
            synthetic_recall.append(float((synthetic >= 0.5).mean()))
        valid_parts.append(valid_idx)

    threshold, _ = best_threshold(y_all, oof)
    valid = [classification_scores(y_all[v], oof[v], 0.5) for v in valid_parts]
    tuned = [classification_scores(y_all[v], oof[v], threshold) for v in valid_parts]
```

Лістинг 3. Крос-валідація з оцінкою на навчальних даних (`src/mk1/comparison.py`)

Метрики класифікації, яких вимагає завдання, обчислено для класу 1: accuracy (частка правильних відповідей), precision (частка справжніх випадків серед позначених моделлю), recall (частка знайдених випадків серед усіх справжніх), F1-міра та ROC-AUC. Додатково наведено PR-AUC — площу під кривою точність-повнота, основну метрику лабораторної роботи №1, що краще за ROC-AUC відображає якість на незбалансованих даних [9], та оцінку Брієра — середній квадрат різниці між імовірністю та фактичним класом, що вимірює

якість самих імовірностей.

Accuracy, precision, recall і F1 залежать від порога рішення, тому їх обчислено за двох порогів:

- **стандартний поріг 0,5**, який використовує метод `predict` бібліотеки scikit-learn;
- **оптимальний поріг**, за якого F1-міра на прогнозах крос-валідації (out-of-fold) максимальна. Для тестової вибірки поріг береться саме звідси, тобто обирається лише на навчальних даних.

Перенавчання виміряно розривом між якістю на навчальних даних і на валідаційних блоках. Якість на навчальних даних обчислено лише на реальних записах навчальної матриці, без синтетичних. Для сценарію B додатково обчислено частку синтетичних записів, які модель відносить до класу 1 за порога 0,5. Якщо модель навчилася розпізнавати синтетичні точки, а не пацієнтів, ця частка буде близькою до 1, а повнота на реальних пацієнтах — значно нижчою. Ті самі навчальні записи також оцінено так, як оцінюється новий пацієнт, тобто пропущено через навчений конвеєр. Різниця між двома оцінками виникає через Target Encoding: рядки навчальної матриці закодовано з перехресним навчанням, а новий пацієнт отримує кодування, навчене на всій навчальній частині.

5. РЕЗУЛЬТАТИ ПОРІВНЯННЯ

Значення всіх метрик для кожного сценарію та моделі наведено на рис. 5.1, а числові результати — у табл. 5.1–5.3.

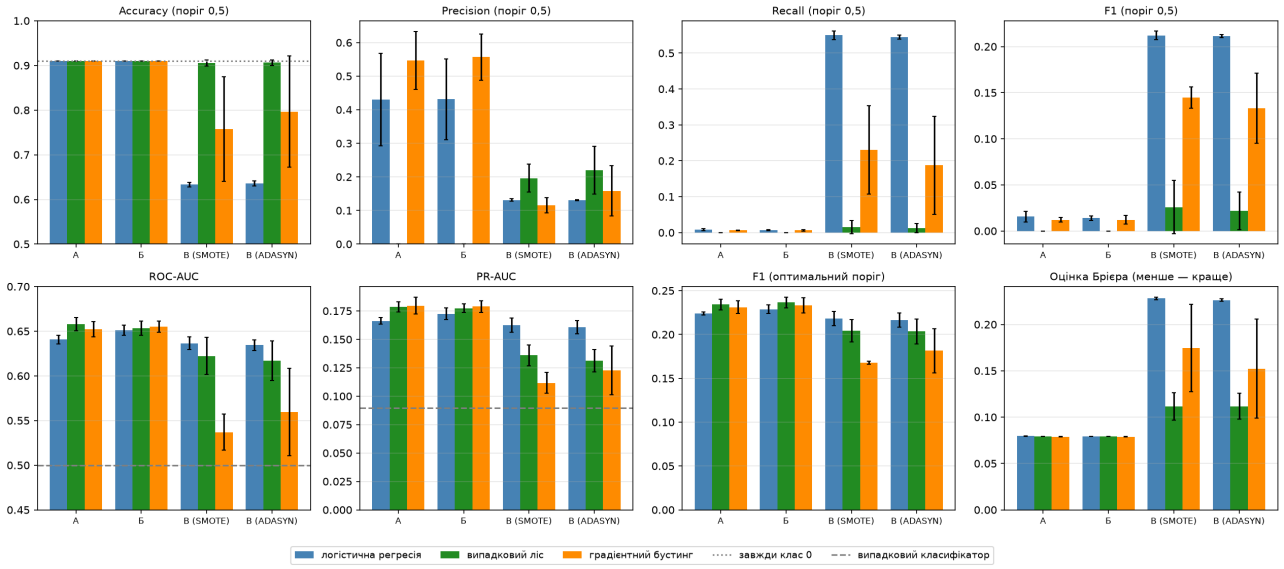


Рис. 5.1. Метрики на валідаційних блоках крос-валідації (середнє ± стандартне відхилення за 5 блоками)

5.1. Метрики за стандартного порога

Таблиця 5.1. Крос-валідація: рішення за порога 0,5

Модель	**Accuracy**	**Precision**	**Recall**	**F1**
А: мінімальне очищення				
логістична регресія	0,910	0,430	0,008	0,016
випадковий ліс	0,910	0,000	0,000	0,000
градієнтний бустинг	0,910	0,547	0,006	0,012
Б: повне очищення				
логістична регресія	0,910	0,431	0,007	0,014
випадковий ліс	0,910	0,000	0,000	0,000
градієнтний бустинг	0,910	0,557	0,006	0,012
В: очищення + SMOTE				
логістична регресія	0,633	0,131	0,550	0,212
випадковий ліс	0,905	0,196	0,015	0,026
градієнтний бустинг	0,758	0,116	0,231	0,145
В: очищення + ADASYN				
логістична регресія	0,635	0,131	0,544	0,211
випадковий ліс	0,906	0,220	0,012	0,022
градієнтний бустинг	0,797	0,158	0,187	0,133

У сценаріях А і Б accuracy усіх трьох моделей дорівнює 0,910, тобто рівно частці класу 0. Моделі майже нікого не відносять до класу 1: recall не перевищує 0,008, а випадковий ліс не позначив жодного пацієнта. Модель, навчена на вибірці з 9 % класу 1, рідко видає ймовірність понад 0,5. Для випадкового лісу це ще помітніше, бо його прогноз — середнє голосів 300 дерев, і ймовірності зсунуті від крайніх значень до середини [10]. За порога 0,5 рішення всіх моделей майже збігаються з тривіальним правилом «завжди клас 0», яке теж має accuracy 0,910. Тому accuracy у цій задачі непридатна для порівняння моделей, а F1-міра за порога 0,5 показує не якість моделі, а невідповідність порога розподілу її ймовірностей.

Аугментація змінює картину. SMOTE піднімає recall логістичної регресії до 0,550, а F1 — з 0,014 до 0,212, хоча accuracy падає до 0,633. На перший погляд аугментація суттєво покращила модель. Насправді вона лише зсунула ймовірності вгору: модель, навчена на вибірці 1 : 1, вважає повторну госпіталізацію подією з шансом близько 50 %, а не 9 %. Той самий ефект можна отримати без аугментації, просто обравши інший поріг [11] (підрозділ 5.3). Для випадкового лісу аугментація майже нічого не змінила за порога 0,5 (recall 0,015), хоча модель навчалася на вибірці 1 : 1. Причину цього розкрито в розділі 6.

5.2. Якість ранжування

Метрики, що не залежать від порога, наведено в табл. 5.2. Вони показують, наскільки добре модель упорядковує пацієнтів за ризиком, і саме за ними коректно порівнювати сценарії.

Таблиця 5.2. Крос-валідація: якість ранжування та ймовірностей

Модель	**ROC-AUC**	**PR-AUC**	**Брієр**
А: мінімальне очищення			
логістична регресія	0,641 ± 0,005	0,166 ± 0,003	0,080
випадковий ліс	0,658 ± 0,007	0,178 ± 0,004	0,079
градієнтний бустинг	0,652 ± 0,008	0,180 ± 0,007	0,079
Б: повне очищення			
логістична регресія	0,651 ± 0,006	0,172 ± 0,005	0,079
випадковий ліс	0,653 ± 0,008	0,177 ± 0,004	0,079
градієнтний бустинг	0,655 ± 0,006	0,179 ± 0,005	0,079
В: очищення + SMOTE			
логістична регресія	0,636 ± 0,007	0,163 ± 0,006	0,228
випадковий ліс	0,622 ± 0,021	0,136 ± 0,009	0,111
градієнтний бустинг	0,537 ± 0,020	0,112 ± 0,009	0,175
В: очищення + ADASYN			
логістична регресія	0,634 ± 0,006	0,161 ± 0,006	0,226
випадковий ліс	0,617 ± 0,022	0,131 ± 0,010	0,112
градієнтний бустинг	0,560 ± 0,049	0,123 ± 0,021	0,152

Повне очищення (А → Б) покращило лише логістичну регресію: ROC-AUC зросла з 0,641 до 0,651, PR-AUC — з 0,166 до 0,172, що перевищує розкид між блоками. Для деревоподібних моделей різниця між сценаріями менша за одне стандартне відхилення: випадковий ліс має PR-AUC 0,178 і 0,177, бустинг — 0,180 і 0,179. Лінійна модель залежить від кожного кроку обробки: без масштабування штраф регуляризації нерівномірно діє на ознаки різного масштабу, а кожна з сотень One-Hot ознак рідкісних категорій отримує власний коефіцієнт. Дерева інваріантні до монотонних перетворень ознак і самі будують розбиття за окремими категоріями, тож масштабування й кодування для них майже нічого не змінюють.

Повне очищення також у 21 раз прискорило навчання логістичної регресії:

1,4 с проти 29,4 с на блок. Немасштабовані лічильники (до 132 аналізів за госпіталізацію) роблять задачу оптимізації погано обумовленою, і розв’язувачу L-BFGS потрібно значно більше ітерацій.

Аугментація погіршила всі моделі. Для логістичної регресії втрата невелика: PR-AUC 0,163 і 0,161 проти 0,172. Для деревоподібних моделей вона суттєва: випадковий ліс втратив 0,041–0,046 PR-AUC, бустинг — 0,056–0,067, а ROC-AUC бустингу з SMOTE (0,537) майже дорівнює рівню випадкового вгадування. Розкид між блоками для деревоподібних моделей з аугментацією зростає у 2–8 разів, тобто результат стає ще й нестабільним.

Оцінка Брієра без аугментації становить 0,079–0,080, що нижче, ніж у сталого прогнозу базової частоти ($0{,}090 \cdot 0{,}910 = 0{,}082$): імовірності моделей відкалібровані. З аугментацією вона зростає до 0,111–0,228, тобто ймовірності перестають відповідати фактичній частоті повторних госпіталізацій. Для моделі клінічного ризику це самостійна втрата [12].

Найвищу якість ранжування на крос-валідації мають деревоподібні моделі: бустинг (PR-AUC 0,180 у сценарії А і 0,179 у Б) та випадковий ліс (0,178 і 0,177). Різниця між ними менша за розкид між блоками. Логістична регресія відстає на 0,005–0,008 PR-AUC навіть після повного очищення.

5.3. Метрики за оптимального порога

Таблиця 5.3. Крос-валідація: рішення за порога, що максимізує F1-міру

Модель	**Поріг**	**Precision**	**Recall**	**F1**
А: мінімальне очищення				
логістична регресія	0,121	0,163	0,359	0,224
випадковий ліс	0,120	0,175	0,354	0,234
градієнтний бустинг	0,105	0,154	0,460	0,231
Б: повне очищення				
логістична регресія	0,103	0,156	0,432	0,229
випадковий ліс	0,117	0,168	0,400	0,237
градієнтний бустинг	0,134	0,193	0,296	0,233
В: очищення + SMOTE				
логістична регресія	0,587	0,159	0,345	0,218
випадковий ліс	0,296	0,140	0,440	0,204
градієнтний бустинг	0,140	0,092	0,943	0,168
В: очищення + ADASYN				
логістична регресія	0,601	0,169	0,300	0,216
випадковий ліс	0,263	0,125	0,594	0,204
градієнтний бустинг	0,257	0,111	0,624	0,181

Без аугментації оптимальний поріг лежить у межах 0,10–0,13, близько до базової частоти класу 1, і дає F1-міру 0,224–0,237. З аугментацією поріг логістичної регресії зсувається до 0,59–0,60, а F1-міра становить 0,218 і 0,216, що нижче, ніж у сценарії Б (0,229). Отже, для лінійної моделі вся видима користь аугментації за порога 0,5 зводиться до зсуву порога, а за правильно обраного порога аугментація дає невеликий програш. Для деревоподібних моделей F1-міра з аугментацією падає до 0,17–0,20. Найвищу F1-міру має випадковий ліс у сценарії Б: 0,237 за precision 0,168 і recall 0,400.

6. АНАЛІЗ ПЕРЕНАВЧАННЯ ТА ВПЛИВУ АУГМЕНТАЦІЇ

6.1. Розрив між навчальними та валідаційними даними

Якість на навчальних даних і на валідаційних блоках порівняно на рис. 6.1 і в табл. 6.1.

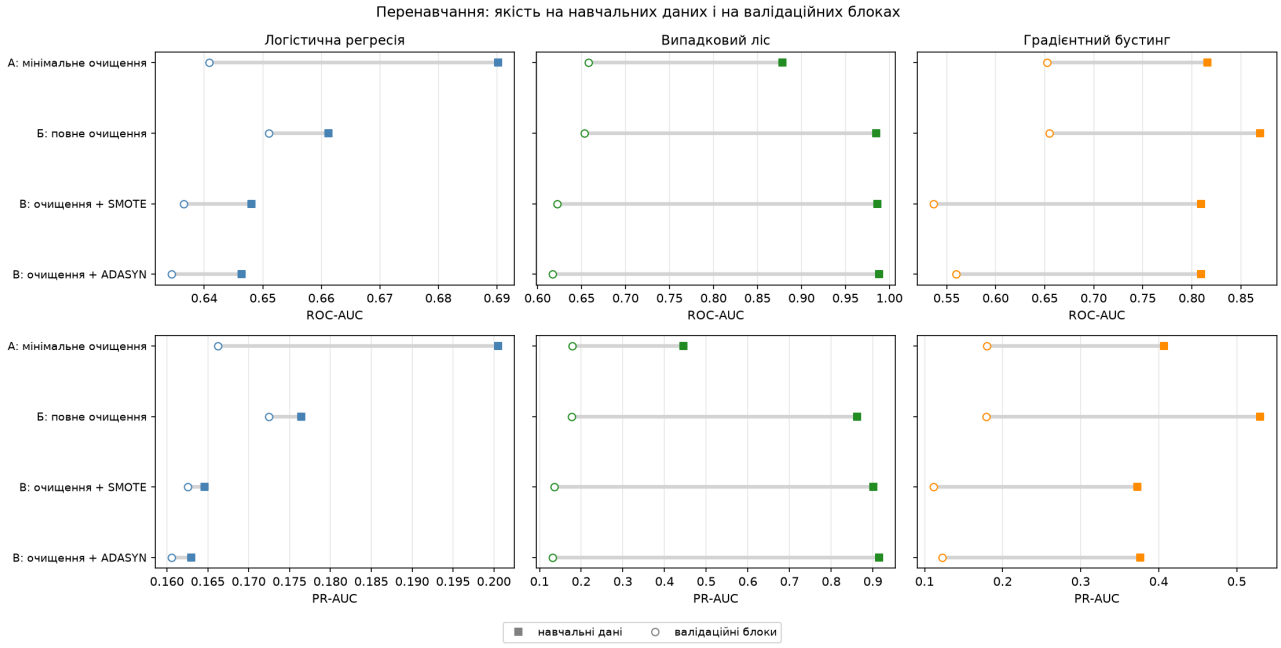


Рис. 6.1. Якість на навчальних даних (квадрати) і на валідаційних блоках (кола)

Таблиця 6.1. Перенавчання: ROC-AUC та частка класу 1, розпізнана за порога 0,5

Модель	ROC-AUC			Recall за порога 0,5			
	навч.	**вал.**	**розрив**	**навч.**	**навч. як нові**	**вал.**	**синтет.**
А: мінімальне очищення							
логістична регресія	0,690	0,641	0,049	0,009	0,009	0,008	—
випадковий ліс	0,878	0,658	0,220	0,000	0,000	0,000	—
градієнтний бустинг	0,816	0,652	0,163	0,020	0,020	0,006	—
Б: повне очищення							
логістична регресія	0,661	0,651	0,010	0,007	0,010	0,007	—
випадковий ліс	0,985	0,653	0,332	0,000	0,000	0,000	—
градієнтний бустинг	0,870	0,655	0,215	0,035	0,026	0,006	—
В: очищення + SMOTE							
логістична регресія	0,648	0,636	0,012	0,568	0,610	0,550	0,614
випадковий ліс	0,986	0,622	0,364	0,102	0,182	0,015	1,000
градієнтний бустинг	0,809	0,537	0,272	0,018	0,369	0,231	0,999
В: очищення + ADASYN							
логістична регресія	0,646	0,634	0,012	0,563	0,602	0,544	0,589
випадковий ліс	0,988	0,617	0,371	0,081	0,165	0,012	1,000
градієнтний бустинг	0,810	0,560	0,250	0,018	0,295	0,187	0,999

Логістична регресія майже не перенавчається: розрив ROC-AUC у сценаріях Б і В становить 0,010–0,012. У сценарії А він уп’ятеро більший (0,049): кожна з майже 500 One-Hot ознак, зокрема рідкісні коди діагнозів, має власний коефіцієнт, і модель частково запам’ятовує шум. Target Encoding стискає кожну високопотужну ознаку до одного числа, тож для лінійної моделі правильне кодування діє як регуляризація: розрив зменшується, а якість на валідації зростає. **Деревоподібні моделі** мають великий розрив навіть без аугментації: випадковий ліс 0,220 і 0,332, бустинг 0,163 і 0,215. Проте саме вони мають найкращу якість на валідації. Розрив вимірює, наскільки модель запам’ятала навчальні записи, але не те, чи шкодить їй це. Кожне дерево лісу запам’ятовує свою бутстреп-вибірку, а усереднення 300 дерев гасить більшу частину цього шуму [5].

З аугментацією розрив деревоподібних моделей зростає (випадковий ліс 0,364 і 0,371, бустинг 0,272 і 0,250), а якість на валідації падає. Ключ до пояснення дають останні стовпці табл. 6.1. Випадковий ліс відносить до класу 1 100 % синтетичних записів, бустинг — 99,9 %. Водночас серед реальних повторно госпіталізованих пацієнтів, на яких ці моделі навчалися, вони розпізнають лише 10,2 % і 1,8 % відповідно. **Моделі навчилися відрізняти синтетичні записи від реальних, а не пацієнтів із ризиком від решти.** Логістична регресія так не може: вона відносить до класу 1 61 % синтетичних записів, 57 % реальних навчальних і 55 % валідаційних, тобто сприймає синтетичні записи так само, як реальні.

6.2. Чому деревоподібні моделі розпізнають синтетичні записи

Синтетичний запис SMOTE лежить на відрізку між двома реальними записами в закодованому просторі ознак. У цьому наборі даних такий запис має значення, яких не буває в реальних пацієнтів:

- **дробові значення One-Hot ознак**. Якщо два сусіди мають різні категорії, синтетичний запис отримує, наприклад, 0,37 у стовпці категорії, а реальні пацієнти мають там лише 0 або 1. Дереву досить двох розбиттів, щоб виділити всі такі записи. Змагальна перевірка в лабораторній роботі №1 відрізняла синтетичні записи від реальних з ROC-AUC 0,98–1,00;
- **проміжні значення Target Encoding**. Через перехресне навчання кожна категорія в навчальній матриці має лише кілька різних значень, по одному на блок. Синтетичні записи заповнюють проміжки між ними. Дерево вивчає правило «точне значення реального запису — клас 0, проміжне значення — клас 1».

Друге правило руйнує прогнози для нових пацієнтів. Новий пацієнт отримує кодування, навчене на всій навчальній частині, і воно не збігається з жодним значенням навчальної матриці. Тому для дерева новий пацієнт схожий на синтетичний запис. Це підтверджує стовпець «навч. як нові» табл. 6.1: ті самі реальні навчальні пацієнти, закодовані так, як кодується новий пацієнт,

відносяться бустингом до класу 1 у 36,9 % випадків замість 1,8 %, а випадковим лісом — у 18,2 % замість 10,2 %. Бустинг фактично ділить пацієнтів на «схожих на навчальні» та «схожих на синтетичні», і цей поділ майже не пов’язаний із ризиком повторної госпіталізації. Звідси ROC-AUC 0,537. У сценаріях без аугментації синтетичних записів немає, і два способи кодування дають майже однакові прогнози 2,6 % проти 3,5 % для бустингу.

6.3. Складність моделі

Щоб перевірити, чи шкода від аугментації є звичайним перенавчанням надто складної моделі, мінімальний розмір листка випадкового лісу змінено від 1 (дерева ростуть до повної чистоти листків) до 100 (неглибокі дерева) у сценаріях Б і В (рис. 6.2, лістинг 4).

```python
# min_samples_leaf of the random forest: 1 grows every tree until each leaf is
# pure, 100 keeps the trees shallow.
LEAF_SIZES = (1, 3, 10, 30, 100)

# Minority-to-majority ratio after SMOTE; "auto" in imbalanced-learn means 1.0.
# The data's own ratio is about 0.1, so 0.25 is the mildest over-sampling.
RATIOS = (0.25, 0.5, 0.75, 1.0)


def capacity_pipeline(scenario: Scenario, leaf: int) -> Pipeline:
    """The scenario's random forest pipeline with the given leaf size."""
    return build_scenario(scenario, "rf").set_params(model__min_samples_leaf=leaf)


def ratio_pipeline(model: str, ratio: float) -> Pipeline:
    """The SMOTE scenario's pipeline with the given minority-to-majority ratio."""
    return build_scenario(SCENARIO_BY_KEY["C-smote"], model).set_params(
        sampler__sampling_strategy=ratio
    )
```

Лістинг 4. Параметри досліджень складності моделі та обсягу аугментації (`src/mk1/overfitting.py`)

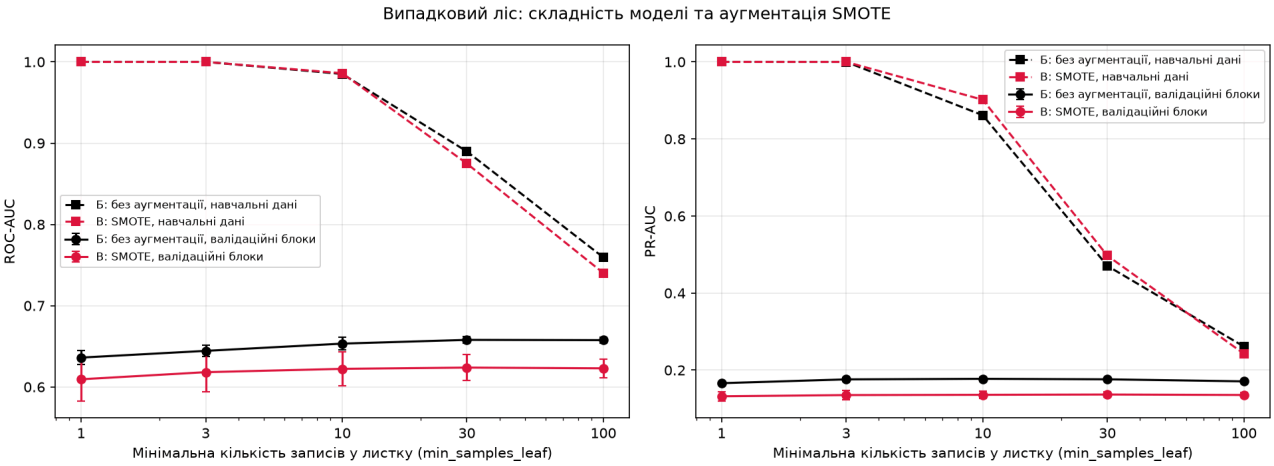


Рис. 6.2. Випадковий ліс: якість на навчальних даних і на валідації залежно від мінімального розміру листка

Без аугментації залежність класична. Дерева з листками по одному запису ідеально запам’ятовують навчальні дані (ROC-AUC 1,000), але мають найгіршу якість на валідації: PR-AUC 0,166, ROC-AUC 0,636. Зі збільшенням листка навчальна ROC-AUC падає до 0,759, а валідаційна зростає до 0,658. PR-AUC максимальна за листка 10 (0,177), тому це значення використано в основному порівнянні.

З аугментацією SMOTE валідаційна PR-AUC лишається в межах 0,132–0,137 за будь-якого розміру листка. Навіть неглибокі дерева з листками по 100 записів відносять до класу 1 97,6 % синтетичних записів. Отже, **регуляризація моделі не усуває шкоди від аугментації**: модель вивчає не випадковий шум окремих записів, а систематичну відмінність синтетичних записів від реальних, і для цього їй не потрібні глибокі дерева.

6.4. Обсяг аугментації

Другий параметр, від якого залежить шкода, — кількість синтетичних записів. SMOTE застосовано з цільовим співвідношенням класів від 0,25 до 1,0. Початкова точка — власне співвідношення даних 0,099 без аугментації (рис. 6.3).

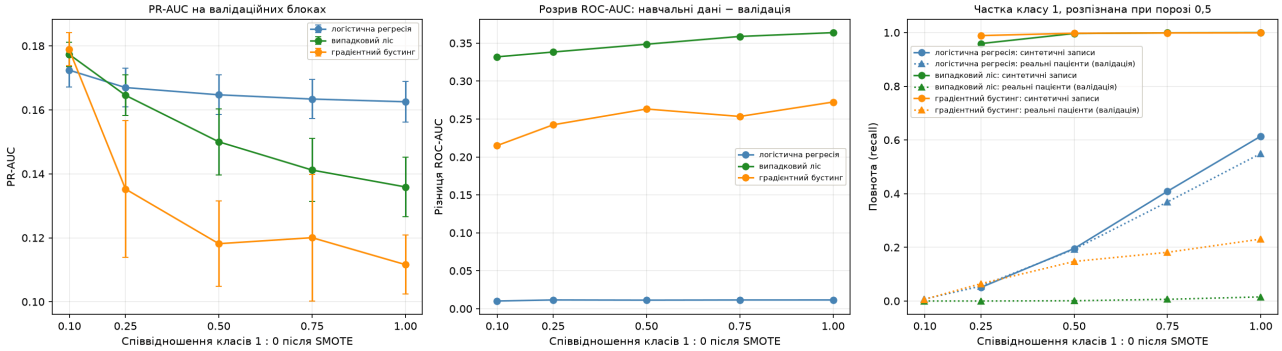


Рис. 6.3. Вплив обсягу аугментації SMOTE на якість, розрив і розпізнавання синтетичних записів

Якість обох деревоподібних моделей монотонно погіршується зі збільшенням частки синтетичних записів. PR-AUC випадкового лісу падає з 0,177 до 0,165, 0,150, 0,141 і 0,136, а розрив ROC-AUC зростає з 0,332 до 0,364. Бустинг втрачає більшу частину якості вже за найменшого співвідношення 0,25: PR-AUC падає з 0,179 до 0,135, і вже тоді він відносить до класу 1 98,9 % синтетичних записів. Для логістичної регресії втрата PR-AUC невелика (з 0,172 до 0,163), розрив не змінюється (0,010–0,012), а частка синтетичних записів, віднесених до класу 1, щоразу близька до recall на реальних валідаційних пацієнтах (від 0,051 і 0,055 до 0,614 і 0,550). Для неї синтетичні записи не відрізняються від реальних, і аугментація лише зсуває ймовірності: оцінка Брієра зростає з 0,079 до 0,228.

6.5. Підсумок: чи покращила аугментація якість передбачення

Аугментація не покращила жодної моделі за жодною метрикою, що не залежить від порога, ні на крос-валідації, ні на тестовій вибірці (розділ 8). Єдине видиме покращення — зростання recall і F1-міри логістичної регресії за порога 0,5 — є наслідком зсуву ймовірностей. Обравши поріг без аугментації, можна отримати вищу F1-міру (0,229 проти 0,218) і відкалібровані ймовірності. Це узгоджується з висновками інших досліджень про те, що за сильних класифікаторів і правильно обраного порога балансування класів не дає переваги [11, 12].

Проведені експерименти дозволяють сформулювати умови, за яких аугментація призводить до перенавчання:

1. **Гнучка модель.** Деревоподібні моделі здатні виділити невелику область простору ознак, де лежать синтетичні записи. Лінійна модель цього не може і тому від аугментації майже не страждає.
2. **Синтетичні записи відрізняються від реальних.** Інтерполяція між дискретними значеннями (лічильники, One-Hot категорії, закодовані значення) дає неможливі для реальних пацієнтів значення. На неперервних ознаках із плавною межею класів SMOTE безпечніший.
3. **Велика частка синтетичних записів.** За співвідношення 1 : 1 синтетичних записів класу 1 приблизно в дев’ять разів більше, ніж реальних, і клас 1 для моделі фактично стає класом синтетичних записів. Шкода зростає з кожним кроком обсягу аугментації.
4. **Різне кодування навчальних і нових записів.** Кодування з перехресним навчанням перед аугментацією робить нових пацієнтів схожими на синтетичних.
5. **Аугментація до розбиття на навчальну та валідаційну частини.** У цій роботі передискретизація стоїть усередині конвеєра й бачить лише навчальні блоки. Якби SMOTE застосували до всієї вибірки перед крос-валідацією, синтетичні сусіди валідаційних записів потрапили б до навчальних даних, і оцінка якості була б завищеною, а не заниженою, як тут.

Важливий методологічний висновок: сам розрив між навчальною та валідаційною якістю не виявляє цієї проблеми. Для випадкового лісу він зріс лише з 0,332 до 0,364, і без аугментації був великим теж. Проблему виявляє порівняння частки розпізнаних синтетичних записів із recall на реальних пацієнтах.

7. СИЛЬНІ ТА СЛАБКІ СТОРОНИ АЛГОРИТМІВ

Сильні та слабкі сторони кожного алгоритму, виявлені в експериментах, зведено в табл. 7.1.

Таблиця 7.1. Сильні та слабкі сторони алгоритмів за результатами експериментів

Алгоритм	**Сильні сторони**	**Слабкі сторони**
Логістична регресія	найменше перенавчання (розрив ROC-AUC 0,010); відкалібровані ймовірності (Брієр 0,079); найшвидше навчання на підготовлених даних (1,4 с); найстійкіша до аугментації (втрата 0,009–0,011 PR-AUC); коефіцієнти можна інтерпретувати як внесок ознак у шанс повторної госпіталізації	найнижча якість ранжування (PR-AUC 0,172 проти 0,177–0,180): лінійна модель не бачить взаємодій ознак; найбільше залежить від обробки даних (без масштабування й кодування PR-AUC 0,166, навчання в 21 раз повільніше)
Випадковий ліс	найкраща якість без обробки даних (на тестовій вибірці PR-AUC 0,190 у сценарії А); не потребує масштабування; стійкий до вибору гіперпараметрів (за листка 3–30 PR-AUC змінюється не більш як на 0,002); дерева навчаються паралельно	запам’ятовує навчальні дані (ROC-AUC 0,985, а за листка 1 — 1,000), тому потребує обмеження розміру листка; ймовірності зсунуті до середини, за порога 0,5 не позначає жодного пацієнта; чутливий до аугментації (втрата до 0,046 PR-AUC); найдовше навчання на підготовлених даних (2,5 с) і найбільший обсяг моделі в пам’яті
Градієнтний бустинг	найвища якість ранжування на крос-валідації (PR-AUC 0,179–0,180); швидке навчання завдяки групуванню значень в інтервали (1,7 с); відкалібровані ймовірності (Брієр 0,079); працює з ознаками різної природи без перетворень	найбільше страждає від аугментації: ROC-AUC з SMOTE 0,537, близько до випадкового вгадування, з великим розкидом між блоками; розрив ROC-AUC 0,215 без аугментації; найбільше гіперпараметрів (кількість дерев, крок навчання, розмір дерева, регуляризація)

Вибір алгоритму залежить від вимог до моделі. Якщо головне — якість

ранжування пацієнтів за ризиком, слід обрати бустинг або випадковий ліс: їхня перевага над логістичною регресією стабільна, а між собою вони рівні в межах розкиду. Якщо потрібні пояснення прогнозу чи робота на погано підготовлених даних із синтетичними записами, логістична регресія надійніша, ціною 0,005–0,012 PR-AUC.

8. ПЕРЕВІРКА НА ТЕСТОВІЙ ВИБІРЦІ

Кожну пару «сценарій — модель» навчено на всій навчальній вибірці та один раз застосовано до 13 998 пацієнтів тестової вибірки. Поріг рішення взято з крос-валідації (табл. 5.3). Результати наведено в табл. 8.1 та на рис. 8.1.

Таблиця 8.1. Результати на тестовій вибірці за порога, обраного на крос-валідації

Модель	**ROC-AUC**	**PR-AUC**	**Поріг**	**Accuracy**	**Precision**	**Recall**	**F1**
А: мінімальне очищення							
логістична регресія	0,649	0,168	0,121	0,783	0,172	0,369	0,234
випадковий ліс	0,663	0,190	0,120	0,797	0,187	0,374	0,249
градієнтний бустинг	0,652	0,186	0,105	0,724	0,152	0,455	0,228
Б: повне очищення							
логістична регресія	0,656	0,178	0,103	0,740	0,157	0,434	0,231
випадковий ліс	0,656	0,187	0,117	0,772	0,172	0,404	0,241
градієнтний бустинг	0,654	0,189	0,134	0,832	0,203	0,297	0,241
В: очищення + SMOTE							
логістична регресія	0,643	0,168	0,587	0,781	0,163	0,348	0,222
випадковий ліс	0,614	0,133	0,296	0,719	0,136	0,399	0,203
градієнтний бустинг	0,516	0,101	0,140	0,167	0,091	0,926	0,166
В: очищення + ADASYN							
логістична регресія	0,642	0,167	0,601	0,809	0,174	0,302	0,221
випадковий ліс	0,599	0,124	0,263	0,529	0,112	0,616	0,190
градієнтний бустинг	0,560	0,115	0,257	0,303	0,097	0,811	0,173

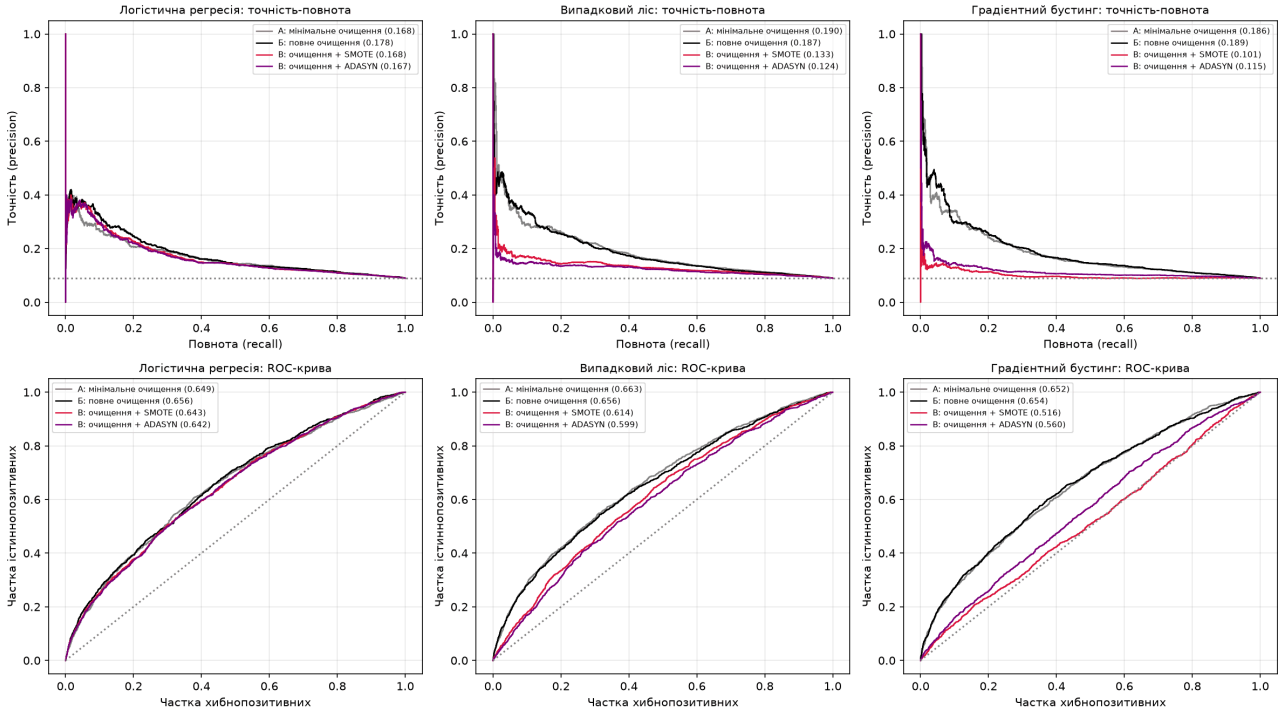


Рис. 8.1. Криві точність-повнота та ROC-криві на тестовій вибірці

Тестова вибірка підтвердила висновки крос-валідації:

- повне очищення покращило логістичну регресію (PR-AUC 0,178 проти 0,168) і не вплинуло на деревоподібні моделі: випадковий ліс 0,190 і 0,187, бустинг 0,186 і 0,189. Ці різниці менші за розкид між блоками на крос-валідації;
- аугментація погіршила всі моделі: логістичну регресію на 0,010–0,011 PR-AUC, випадковий ліс на 0,054–0,063, бустинг на 0,074–0,088. ROC-AUC бустингу з SMOTE становить 0,516, тобто на тестовій вибірці він ранжує пацієнтів майже випадково;
- найкращі результати мають випадковий ліс у сценарії А (PR-AUC 0,190, ROC-AUC 0,663, F1 0,249) та бустинг у сценарії Б (PR-AUC 0,189). Базовий рівень PR-AUC випадкового класифікатора становить 0,090.

Пороги, обрані на крос-валідації, добре переносяться на нові дані, якщо модель навчалася без аугментації. Бустинг у сценарії Б з порогом 0,134 відносить до групи ризику 1 834 пацієнтів (13,1 % тестової вибірки). Серед них 373 справді повернулися до лікарні протягом 30 днів: precision 0,203, у 2,3 раза вище за базову

частоту, recall 0,297. F1-міра на тесті (0,241) навіть вища, ніж на крос-валідації (0,233). Натомість бустинг з SMOTE з порогом 0,140 відносить до групи ризику 12 731 пацієнта (91 % вибірки), і його precision 0,091 не відрізняється від базової частоти. Імовірності моделі, навченої на синтетичних даних, нестабільні, і поріг, обраний на крос-валідації, на нових даних не працює.

За порога 0,5 accuracy моделей сценаріїв А і Б на тестовій вибірці становить 0,910–0,911, як і в тривіального правила «завжди клас 0». За обраних порогів accuracy нижча (0,72–0,83), але моделі знаходять 30–46 % усіх повторних госпіталізацій. Оцінка Брієра моделей без аугментації (0,0785–0,0795) нижча за рівень сталого прогнозу 0,082, а з аугментацією становить 0,109–0,227.

9. ВИСНОВКИ

У лабораторній роботі порівняно три алгоритми класифікації — логістичну регресію, випадковий ліс і гістограмний градієнтний бустинг — на чотирьох варіантах підготовки даних Diabetes 130-US Hospitals для задачі передбачення повторної госпіталізації протягом 30 днів.

1. Accuracy непридатна для цієї задачі: усі моделі без аугментації мають 0,910 за порога 0,5, рівно стільки ж, скільки правило «завжди клас 0», і майже нікого не відносять до класу 1. Коректне порівняння дають метрики, що не залежать від порога (ROC-AUC, PR-AUC), та F1-міра за порога, обраного на навчальних даних.
2. Повне очищення даних важливе для логістичної регресії: PR-AUC зросла з 0,166 до 0,172 на крос-валідації та з 0,168 до 0,178 на тестовій вибірці, розрив між навчальною і валідаційною якістю зменшився вп’ятеро, а навчання прискорилося в 21 раз. Деревоподібні моделі до обробки байдужі: різниця між сценаріями А і Б для них менша за розкид між блоками.
3. Найвищу якість ранжування мають деревоподібні ансамблі: бустинг (PR-AUC 0,179–0,180 на крос-валідації) і випадковий ліс (0,177–0,178,

а на тестовій вибірці 0,190). Логістична регресія відстає на 0,005–0,012 PR-AUC, але має найменше перенавчання і найпростіше пояснення прогнозу. Усі моделі без аугментації дають відкалібровані ймовірності (Брієр 0,079).

4. Аугментація SMOTE і ADASYN не покращила жодної моделі. Видиме зростання recall і F1-міри логістичної регресії за порога 0,5 є лише зсувом ймовірностей: за правильно обраного порога F1-міра з аугментацією нижча (0,218 проти 0,229), а оцінка Брієра зростає втричі. Деревоподібні моделі втратили 0,041–0,067 PR-AUC на крос-валідації; ROC-AUC бустингу з SMOTE на тестовій вибірці становить 0,516.
5. Аугментація викликала перенавчання особливого роду: деревоподібні моделі відносять до класу 1 99,9–100 % синтетичних записів і лише 1,8–10,2 % реальних пацієнтів із повторною госпіталізацією, на яких навчалися. Вони навчилися відрізняти синтетичні записи від реальних за дробовими значеннями One-Hot ознак і проміжними значеннями Target Encoding. Регуляризація моделі цього не усуває, а збільшення частки синтетичних записів посилює.
6. Аугментація призводить до перенавчання, коли модель гнучка, синтетичні записи мають неможливі для реальних даних значення (дискретні та закодовані ознаки), їх частка велика, а кодування навчальних і нових записів різне. Розрив між навчальною та валідаційною якістю цього не виявляє; виявляє порівняння частки розпізнаних синтетичних записів із recall на реальних даних.

Головний висновок роботи: вибір алгоритму та вибір підготовки даних не можна робити окремо. Логістична регресія потребує ретельної обробки, але стійка до синтетичних даних; деревоподібні ансамблі дають кращу якість без обробки, але найбільше страждають від аугментації. Для незбалансованої задачі з дискретними ознаками найкращим рішенням виявилося не синтезувати дані, а навчати модель на реальних даних і обирати поріг рішення на крос-валідації.

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ

[1] Strack B., DeShazo J. P., Gennings C. et al. Impact of HbA1c Measurement on Hospital Readmission Rates: Analysis of 70,000 Clinical Database Patient Records // BioMed Research International. 2014. Vol. 2014. Article ID 781670.

[2] Chawla N. V., Bowyer K. W., Hall L. O., Kegelmeyer W. P. SMOTE: Synthetic Minority Over-sampling Technique // Journal of Artificial Intelligence Research. 2002. Vol. 16. P. 321–357.

[3] He H., Bai Y., Garcia E. A., Li S. ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning // Proc. IEEE International Joint Conference on Neural Networks. 2008. P. 1322–1328.

[4] Micci-Barreca D. A Preprocessing Scheme for High-Cardinality Categorical Attributes in Classification and Prediction Problems // ACM SIGKDD Explorations Newsletter. 2001. Vol. 3, No. 1. P. 27–32.

[5] Breiman L. Random Forests // Machine Learning. 2001. Vol. 45, No. 1. P. 5–32.

[6] Friedman J. H. Greedy Function Approximation: A Gradient Boosting Machine // The Annals of Statistics. 2001. Vol. 29, No. 5. P. 1189–1232.

[7] Ke G., Meng Q., Finley T. et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree // Advances in Neural Information Processing Systems 30. 2017. P. 3146–3154.

[8] Chang C.-C., Lin C.-J. LIBSVM: A Library for Support Vector Machines // ACM Transactions on Intelligent Systems and Technology. 2011. Vol. 2, No. 3. Article 27.

[9] Saito T., Rehmsmeier M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets // PLoS ONE. 2015. Vol. 10, No. 3. e0118432.

[10] Niculescu-Mizil A., Caruana R. Predicting Good Probabilities with Supervised Learning // Proc. 22nd International Conference on Machine Learning. 2005. P. 625–632.

[11] Elor Y., Averbuch-Elor H. To SMOTE, or not to SMOTE? // arXiv preprint arXiv:2201.08528. 2022.

[12] van den Goorbergh R., van Smeden M., Timmerman D., Van Calster B. The harm of class imbalance corrections for risk prediction models: illustration and simulation using logistic regression // Journal of the American Medical Informatics Association. 2022. Vol. 29, No. 9. P. 1525–1534.